

# THÔNG TIN ĐỀ TÀI ĐỒ ÁN CƠ SỞ

## 1. Tên đề tài (ghi IN HOA)

XÂY DỰNG HỆ THỐNG PHÁT HIỆN WEBSITE LỪA ĐẢO (PHISHING) DỰA TRÊN URL

## 2. Sinh viên thực hiện:

Họ tên: Kim Ngọc Hoàng

MSSV: 2380600714

Họ tên: Lê Anh Huy

MSSV: 2380600820

## BÁO CÁO TIẾN ĐỘ

### Nội dung

#### 1.1 Mục tiêu

- Hoàn thiện pipeline dữ liệu phục vụ huấn luyện cho Domain Model và URL Model.
- Tách riêng bộ đặc trưng cho hai bài toán domain và URL để phản ánh đúng đặc thù dữ liệu đầu vào.
- Mở rộng benchmark mô hình và chốt cấu hình chính thức có thể dùng cho bước triển khai hệ thống sau này.

#### 1.2 Công việc thực hiện

- Hoàn thiện luồng xử lý dữ liệu từ tải dữ liệu, chuẩn hóa, làm sạch, tạo dataset riêng cho Domain Model và URL Model.
- Tách riêng feature engineering: Domain Model dùng 15 đặc trưng theo hostname/domain; URL Model dùng 37 đặc trưng lexical cho full URL.
- Bổ sung và benchmark các mô hình gồm Logistic Regression, Linear SVM, Random Forest, XGBoost, ANN (MLP) và Hybrid (Logistic Regression + XGBoost + ANN).
- Chạy thử nghiệm nhiều mô hình, cuối cùng chọn được mô hình chính thức cho đề án là: Hybrid (Logistic Regression + XGBoost + ANN).

#### 1.3 Kết quả đạt được

| Hạng mục          | Domian Model | Url Model    | Ghi chú                                                    |
|-------------------|--------------|--------------|------------------------------------------------------------|
| Số lượng dataset  | 54,042 dòng  | 100,717 dòng | Dữ liệu đã được chọn sau khi đã qua các bước lọc, làm sạch |
| Số lượng phishing | 27,021       | 62,638       | Domain đã cân bằng; URL giữ                                |

|                            |                                                                                                        |                                                                                                        |  |                                                   |
|----------------------------|--------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|--|---------------------------------------------------|
|                            |                                                                                                        |                                                                                                        |  | phân bố hiệu quả                                  |
| Số lượng benign            | 27,021                                                                                                 | 38,079                                                                                                 |  | Dùng để đối chiếu class balance giữa hai bài toán |
| Số feature                 | 15                                                                                                     | 37                                                                                                     |  | Domain và URL đã tách bộ feature riêng            |
| Validation PR-AUC (hybrid) | 0.9821                                                                                                 | 0.9763                                                                                                 |  | Tiêu chí dùng để chọn model tốt nhất              |
| Test PR-AUC (hybrid)       | 0.9846                                                                                                 | 0.9872                                                                                                 |  | Chỉ số tổng hợp quan trọng cho bài toán lệch lớp  |
| F1-Score (hybrid)          | 0.9318                                                                                                 | 0.9600                                                                                                 |  | Dùng để quan sát cân bằng precision và recall     |
| Precision (hybrid)         | 1.0                                                                                                    | 1.0                                                                                                    |  | Chỉ số đánh giá mô hình                           |
| Recall (hybrid)            | 0.8117                                                                                                 | 0.7949                                                                                                 |  | Chỉ số đánh giá mô hình                           |
| Thuật toán benchmark       | logistic_regression,<br>linear_svm,<br>random_forest,<br>xgboost,<br>ann_mlp,<br>hybrid_lr_xgboost_ann | logistic_regression,<br>linear_svm,<br>random_forest,<br>xgboost,<br>ann_mlp,<br>hybrid_lr_xgboost_ann |  | Các thuật toán dùng để train                      |

1.4 Khó khăn gặp phải

- Dữ liệu Domain Model ban đầu bị lệch lớp lớn, benign nhiều hơn phishing nên kết quả validation dao động mạnh theo từng mốc thời gian.

- Bài toán domain khó hơn URL vì không còn tín hiệu từ path, query và fragment, do đó cần thiết kế lại bộ đặc trưng để phản ánh đúng hostname.

### 1.5 Kế hoạch tiếp theo

- Xây dựng bước suy luận cho IDS/dashboard, trong đó Domain Model và URL Model official sẽ được dùng làm đầu ra mặc định.
- Thiết kế risk score và ngưỡng cảnh báo phù hợp để hiển thị trên dashboard hoặc gửi thông báo cho người dùng.
- Tiếp tục bổ sung dữ liệu mới, retrain định kỳ và đánh giá lại mức độ ổn định của Hybrid Model trước khi đưa vào demo hệ thống hoàn chỉnh.